


ARQUITECTURA DE BIG DATA ANALYTICS POR CAPAS PARA LA DETECCION DE AUDIO DEEPFAKE CON WAV2VEC 2.0 Y APACHE SPARK

Milagros Valverde | Sebastian Minchola | Sebastian Guevara | Fiorella Tamariz | Margot Torre

¿PODRÍAS CONFIAR EN UNA LLAMADA?

Imagina recibir una llamada con la voz de un familiar pidiéndote dinero urgente.

¿ES REAL... O UN
DEEPPFAKE?



INTRODUCCIÓN

Para realizar fraude mediante suplantación de identidad de una persona solo se requieren muestras breves su voz.

Caso Arup: se
perdieron \$25 MM
mediante un fraude
por videollamada.

MFCC → wav2vec

Problema abordado:

Detectar **audios falsos** en escenarios reales.

PREGUNTA DE INVESTIGACIÓN

¿Cómo organizar una **arquitectura** por capas que integre **audio crudo** y **embeddings precomputados**, aplique controles de calidad, prepare datos con Spark y permita evaluar **clasificadores de audio deepfake** de forma trazable?



OBJETIVO DEL PROYECTO


General:

Diseñar, implementar y evaluar dicha arquitectura usando **Parquet**, **wav2vec 2.0**, **tablas persistentes** y **Spark ML**, midiendo tanto **volumen** como **tiempo** por etapa.

Específicos:

- Conservar y describir las fuentes en la capa Workload.
- Persistir embeddings externos y procedencia en la capa Landing.
- Validar tipos, completitud y unicidad en la capa Curated.
- Integrar y ensamblar las características en la capa Functional.
- Registrar volumen y tiempo por etapa; y
- Evaluar modelos con métricas adecuadas para un test desbalanceado.

ARQUITECTURA



WORKLOAD

Fuentes originales tanto en formato parquet y zip que contiene los audios en wav.

TRANSICIÓN

Se procesan los archivos wav para convertirlos en datos tabulares.

LANDING

Se reciben las observaciones con sus 768 dimensiones + etiqueta REAL o FAKE.

CURATED


Se convierten las variables a double y se excluyen obs. con valores inválidos.

FUNCTIONAL

Se integran las dimensiones en vectores usando VectorAssembler.


MODELOS DE ML

- Regresión Logística
- Random Forest
- Gradient Boosted Trees




CAPA WORKLOAD

Fuente	Formato	Volumen	Unidad
Train ASVspoof	Parquet	550,185	filas · 768D
Test ASVspoof	Parquet	138,105	filas · 768D
Audio YouTube (REAL)	WAV	1,005	segmentos válidos



CAPA LANDING



CAPA CURATED

- Validación de calidad de datos

**Dimensiones del
embedding**

768

**Archivos fuente
únicos**

1005

Nulos / NaN

0

**Fuentes con
múltiples
segmentos**

0

- Conversión de variables a tipo DOUBLE.
- Homologación del esquema para su integración posterior.

CAPA FUNCIONAL

1

Integración de los embeddings externos con el conjunto de entrenamiento original.

2

Construcción de la variable features mediante VectorAssembler.

3

Generación del dataset final listo para Machine Learning.

BALANCEO Y MODELADO

Codificación de etiquetas:

REAL = 0
FAKE = 1

Balanceo de Clases

Aplicación de undersampling para balancear las clases.

Entrenamiento de tres modelos

- Regresión Logística.
- Random Forest.
- Gradient Boosted Trees (GBT).

BALANCEO Y MODELADO

Codificación de etiquetas:

REAL = 0
FAKE = 1

Balanceo de Clases

Aplicación de undersampling para balancear las clases.

Entrenamiento de tres modelos

- Regresión Logística.
- Random Forest.
- Gradient Boosted Trees (GBT).

Evaluación

Métricas de evaluación: Accuracy, Precision, Recall, F1-Score, ROC-AUC.
Métricas complementarias: PR-AUC, Macro-F1, Balanced Accuracy y EER.

RESULTADOS

RESULTADOS

PARTICIPACIÓN DE CLASES POR ETAPA




Figura 2. Participación de REAL en el train original, enriquecido y balanceado.

DATOS POR ETAPA




Figura 3. Volumen de registros por etapa; la escala logarítmica permite comparar magnitudes distintas.

TIEMPOS DE EJECUCIÓN

RESULTADOS

Tabla VI
TIEMPO REGISTRADO POR ETAPA DEL PIPELINE.

Capa/ámbito	Etapa	min	Capa/ámbito	Etapa	min
Preparación	Entorno y dependencias	1.85	Functional	Integración y ensamblaje	3.10
Workload	Lectura y descubrimiento	1.10	Consumo ML	Undersampling	0.65
Workload–Landing	Carga wav2vec	0.95	Consumo ML	Regresión Logística	1.22
Workload–Landing	Conversión a embeddings	13.75	Consumo ML	Random Forest	2.35
Curated	Calidad y persistencia	0.48	Consumo ML	GBT	4.95
Resultados	Evaluación y exportación	1.88	Transversal	Operaciones auxiliares	2.95
Tiempo total					35.23

COMPARACIÓN DE MODELOS





Figura 4. Curvas ROC y Precision–Recall calculadas a partir de los scores de FAKE. La elevada prevalencia de FAKE debe considerarse al interpretar PR-AUC.

RESULTADOS

MATRIZ DE CONFUSIÓN - LOGISTIC REGRESSION

Muestra un **desempeño equilibrado** entre clases, con recall REAL de 0.837 y recall FAKE de 0.840. Sin embargo, los **21,104 falsos negativos FAKE** representan el error más crítico en un escenario de detección de fraude.



CONCLUSIONES

- **Arquitectura 100% Trazable:** La implementación de las 4 capas (Workload a Functional) permitió un flujo auditable desde el audio crudo hasta el ML. Las aserciones automatizadas de cardinalidad y calidad reemplazaron con éxito la inspección manual.
- **El Valor de Persistir Datos:** La extracción de embeddings (wav2vec) es el principal cuello de botella (tomó ~14 de los 35 min totales). Guardar estos datos en la capa Landing es vital para no recalcularlos al reentrenar.
- **La Trampa del Desbalance:** Aunque Regresión Logística logró el mejor balance global (ROC-AUC: 0.92), un F1 ponderado alto esconde el bajo rendimiento en la clase minoritaria (F1 FAKE: 0.32). El fraude exige evaluar métricas por clase.



LIMITACIONES Y TRABAJOS FUTUROS

LIMITACIONES

- Se realizó una sola **corrida serverless**, lo cual no permite sacar conclusiones sobre escalabilidad horizontal.
- El **undersampling** descarta alrededor del **95%** de los **audios FAKE** y puede excluir ataques poco frecuentes.
- Posible **cambio de dominio** entre ASVspoof y la voz de YouTube.
- EER por observación, no por archivo: no comparable con el protocolo oficial.

TRABAJOS FUTUROS

- Paralelizar o servir la extracción wav2vec (el mayor cuello de botella).
- Comparar undersampling con pesos de clase y estrategias híbridas.
- Reservar un test externo por fuente y evaluar por archivo.
- Fijar todas las semillas, calibrar umbrales y medir varias corridas.

GRACIAS

POR SU ATENCIÓN

- [1] M. Westerlund, "The emergence of deepfake technology: A review," Technology Innovation Management Review, vol. 9, no. 11, pp. 39–52, 2019.
- [2] Europol cement 2022, lable: Innovation and the consultado Lab, "Facing challenge en junio of de reality? law deepfakes," 2026. [Online]. enfor Europol, Avai <https://www.europol.europa.eu/publications-events/publications/facing-reality-law-enforcement-and-challenge-of-deepfakes>
- [3] Federal Trade Commission, "Scammers use ai to enhance their family emergency schemes," Consumer Advice, 2023, consultado en junio de 2026. [Online]. Available: <https://consumer.ftc.gov/consumer-alerts/2023/03/scammers-use-ai-enhance-their-family-emergency-schemes>
- [4] Financial Times, "Arup lost \$25mn in hong kong deepfake video conference scam," Financial Times, May 2024, consultado en junio de 2026. [Online]. Available: <https://www.ft.com/content/b977e8d4-664c-4ae4-8a8e-eb93bdf785ea>
- [5] Reuters, "Malicious actors using ai to pose as senior us officials, fbi says," Reuters, May 2025, consultado en junio de 2026. [Online]. Available: <https://www.reuters.com/world/us/malicious-actors-using-ai-pose-senior-us-officials-fbi-says-2025-05-15/>
- [6] J. Yamagishi, X. Wang, M. Todisco, M. Sahidullah, J. Patino, A. Nautsch, X. Liu, K. A. Lee, T. Kinnunen, N. Evans, and H. Delgado, "Asvspoof 2021: Accelerating progress in spoofed and deepfake speech detection," in Proceedings of the 2021 Edition of the Automatic Speaker Verification and Spoofing Countermeasures Challenge, 2021, pp. 47–54.
- [7] ASVspoof Consortium, "Asvspoof 2021 challenge: Speech deepfake database," Zenodo, 2021. [Online]. Available: <https://doi.org/10.5281/zenodo.4835108>
- [8] X. Liu, X. Wang, M. Sahidullah, J. Patino, H. Delgado, T. Kinnunen, M. Todisco, J. Yamagishi, N. Evans, A. Nautsch, and K. A. Lee, "Asvspoof 2021: Towards spoofed and deepfake speech detection in the wild," IEEE/ACM Transactions on Audio, Speech, and Language Processing, vol. 31, pp. 2507–2522, 2023.
- [9] Y. Li, M. Zhang, M. Ren, X. Qiao, M. Ma, D. Wei, and H. Yang, "Cross-domain audio deepfake detection: Dataset and analysis," in Proceedings of the 2024 Conference on Empirical Methods in Natural Language Processing. Miami, Florida, USA: Association for Computational Linguistics, 2024, pp. 4977–4983. [Online]. Available: <https://aclanthology.org/2024.emnlp-main.286/>
- [10] O. C. Phukan, G. S. Kashyap, A. B. Buduru, and R. Sharma, "Heterogeneity over homogeneity: Investigating multilingual speech pre-trained models for detecting audio deepfake," 2024. [Online]. Available: <https://arxiv.org/abs/2404.00809>
- [11] A. Baevski, H. Zhou, A. Mohamed, and M. Auli, "wav2vec 2.0: A framework for self-supervised learning of speech representations," Advances in Neural Information Processing Systems, vol. 33, pp. 12449–12460, 2020. [Online]. Available: <https://proceedings.neurips.cc/paper/2020/hash/92d1e1eb1cd6f9fba3227870bb6d7f07-Abstract.html>
- [12] T. Kang, S. Han, S. Choi, J. Seo, S. Chung, S. Lee, S. Oh, and I.-Y. Kwak, "Experimental study: Enhancing voice spoofing detection models with wav2vec 2.0," 2024. [Online]. Available: <https://arxiv.org/abs/2402.17127>

- [13] X. Meng, J. Bradley, B. Yavuz, E. Sparks, S. Venkataraman, D. Liu, J. Freeman, D. B. Tsai, M. Amde, S. Owen, D. Xin, R. Xin, M. J. Franklin, R. Zadeh, M. Zaharia, and A. Talwalkar, "Mllib: Machine learning in apache spark," Journal of Machine Learning Research, vol. 17, no. 34, pp. 1–7, 2016. [Online]. Available: <https://www.jmlr.org/papers/v17/15-237.html>
- [14] M. Armbrust, A. Ghodsi, R. Xin, and M. Zaharia, "Lakehouse: A new generation of open platforms that unify data warehousing and advanced analytics," in 11th Annual Conference on Innovative Data Systems Research (CIDR 2021), 2021. [Online]. Available: <https://www.cidrdb.org/cidr2021/papers/cidr2021paper17.pdf>
- [15] Databricks, "Databricks free edition limitations," Databricks Documentation, 2026, consultado en junio de 2026. [Online]. Available: <https://docs.databricks.com/aws/en/getting-started/free-edition-limitations>
- [16] B. Krawczyk, "Learning from imbalanced data: Open challenges and future directions," Progress in Artificial Intelligence, vol. 5, pp. 221–232, 2016.
- [17] T. Saito and M. Rehmsmeier, "The precision-recall plot is more informative than the roc plot when evaluating binary classifiers on imbalanced datasets," PLOS ONE, vol. 10, no. 3, p. e0118432, 2015.
- [18] H. Delgado, N. Evans, T. Kinnunen, K. A. Lee, X. Liu, A. Nautsch, J. Patino, M. Sahidullah, M. Todisco, X. Wang, and J. Yamagishi, "Asvspoof 2021: Automatic speaker verification spoofing and countermeasures challenge evaluation plan," 2021. [Online]. Available: <https://arxiv.org/abs/2109.00535>
- [19] D. R. Cox, "The regression analysis of binary sequences," Journal of the Royal Statistical Society: Series B, vol. 20, no. 2, pp. 215–242, 1958.
- [20] L. Breiman, "Random forests," Machine Learning, vol. 45, no. 1, pp. 5–32, 2001.
- [21] J. H. Friedman, "Greedy function approximation: A gradient boosting machine," The Annals of Statistics, vol. 29, no. 5, pp. 1189–1232, 2001