DETECCIÓN DE FRAUDE POR VOZ MEDIANTE DEEPFAKES:

ANALISIS DE REPRESENTACIONES DE AUDIO Y MODELOS DE CLASIFICACION EN ESCENARIOS REALES

Milagros Valverde | Sebastian Minchola | Sebastian Guevara | Fiorella Tamariz | Margot Torre

¿PODRÍAS CONFIAR EN UNA LLAMADA?

Imagina recibir una llamada con la voz de un familiar pidiéndote dinero urgente.

¿ES REAL... O UN DEEPFAKE?

INTRODUCCIÓN

El avance reciente en tecnologías de IA permite generar contenido sintético altamente realista, como la voz humana. El uso de modelos de deep learning dio lugar a los *audio deepfakes* (imitación de la voz de una persona real).

Crecimiento exponencial (2022-2023):
10x a nivel mundial
410% en América Latina

MFCC → *wav2vec*

Problema abordado:
Detectar **audios falsos** en escenarios reales.

PREGUNTAS DE INVESTIGACIÓN

¿Es posible diferenciar de manera efectiva entre audios reales y audios generados mediante técnicas de deepfake utilizando representaciones de audio basadas en modelos de aprendizaje profundo?

¿Qué impacto tiene la elección de la representación de audio en el desempeño de los modelos de clasificación en la tarea de detección de voces falsas?

¿Qué limitaciones presenta este tipo de enfoque en términos de generalización frente a datos no vistos o provenientes de contextos reales?

OBJETIVOS DEL PROYECTO

GENERAL:

Desarrollar y evaluar un **modelo de clasificación** para detectar **deepfakes** de voz.

ESPECÍFICOS:

- Implementar un **pipeline de procesamiento distribuid**o.
- Entrenar y comparar modelos de clasificación binaria.
- Analizar **métricas clave**: Precision, Recall y AUC.
- Analizar el **impacto** de diferentes estrategias de representación de audio en el desempeño del modelo.
- Evaluar la **capacidad** de generalización del modelo.

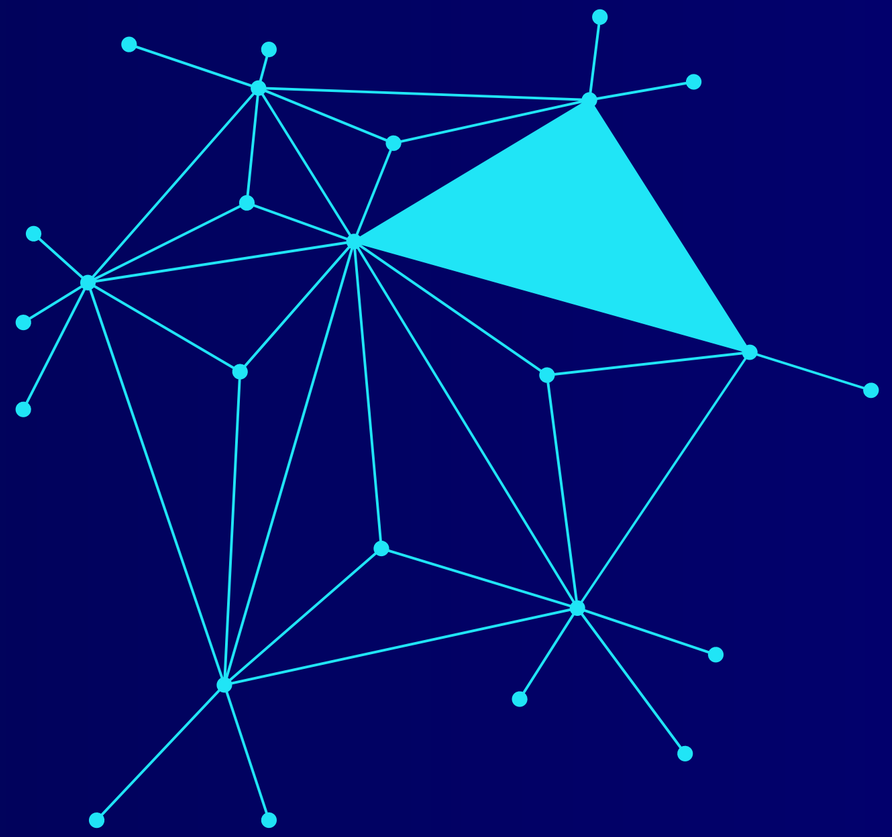

ESTADO DEL ARTE

Kang et al. — wav2vec 2.0 para detectar voice spoofing

Tema:
Detección de ataques de **suplantación de voz** mediante representaciones profundas de audio.

Problema:
Los métodos tradicionales, como **MFCC**, pueden no capturar patrones complejos presentes en **audios sintéticos modernos**.

Modelo / enfoque:
Uso de **wav2vec 2.0** como extractor de características, selección de capas y modelos de clasificación como **RawNet2** y **AASIST**.

Resultado clave:
- Mejora significativa en detección frente a **métodos tradicionales**
- Mayor capacidad para capturar **patrones complejos**

ESTADO DEL ARTE

Li et al. — Deepfake detection entre dominios

Tema:
Detección de **audios deepfake** cuando los datos provienen de **distintas fuentes o sistemas de síntesis**.

Problema:
Un modelo puede **funcionar bien en datos conocidos**, pero fallar cuando se enfrenta a audios generados por **sistemas nuevos.**

Modelo / enfoque:
Uso de **modelos preentrenados**, incluyendo variantes de **wav2vec**, evaluados sobre un dataset amplio con más de 300 horas de audio sintético.

Resultado clave:
- Buen desempeño en **entornos controlados**
- Caída de rendimiento en **datos no vistos**

ESTADO DEL ARTE

Chetia Phukan et al. — Modelos multilingües para audio deepfake

Tema:
Evaluación de modelos de **representación de voz** preentrenados en **distintos idiomas** para detectar **audios falsos**.

Problema:
Los modelos entrenados en **un solo idioma pueden tener limitaciones** cuando se aplican a contextos más diversos.

Modelo / enfoque:
Comparación entre modelos **monolingües** y modelos **multilingües** usando datasets como **ASVspoof 2019 e In-the-Wild.**

Resultado clave:
- Mejor desempeño en **escenarios diversos**
- Mayor capacidad de **generalización**

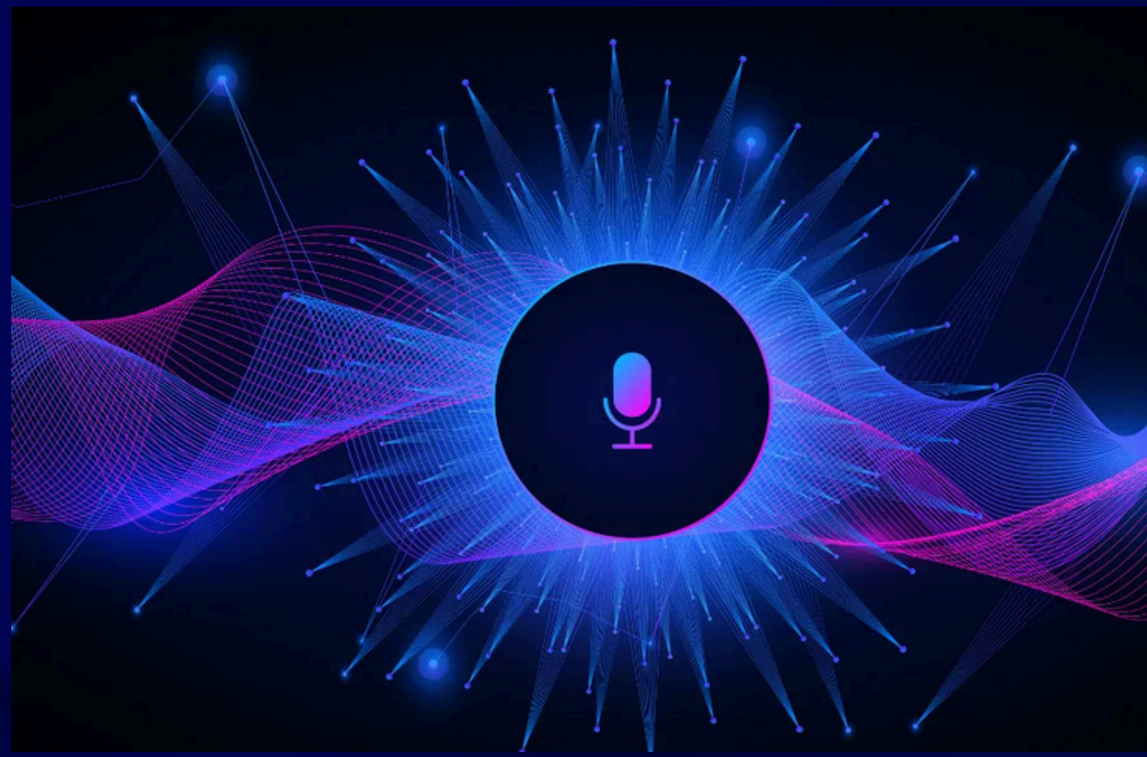

DESCRIPCIÓN DEL DATASET

FUENTE: DeepFakeVoice-Wav2Vec (Basado en ASVspoof 2021).

VOLUMEN:

- Entrenamiento: 1.7 GB.
- Prueba: 426 MB.

CONTENIDO:

- Un conjunto de variables numéricas correspondientes a los embeddings (emb_*)
- Una etiqueta categórica que indica si el audio es real o falso.

FORMATO: Embeddings de 768 dimensiones.

PIPELINE DE PROCESAMIENTO

CARGA DE DATOS

En formato parquet desde almacenamiento distribuido (volúmenes)

EMBEDDINGS

Las columnas de embeddings se combinan en un vector de características usando VectorAssembler.

FEATURES

La variable target pasa a formato binario: real & fake → 0 & 1.

BALANCEO DE DATOS

Ajuste de clases (undersampling) para evitar sesgo del modelo.

MODELO

- Regresión Logística
- Random Forest
- Gradient Boosted Trees

EVALUACIÓN

- Precision
- Recall (clave en fraude)
- AUC

RESULTADOS

DISTRIBUCIÓN DE CLASES

Conjunto	Clase	Cantidad
Entrenamiento (original)	Fake (1)	525,677
	Real (0)	24,508
Entrenamiento (balanceado)	Fake (1)	24,479
	Real (0)	24,508

Cuadro I
DISTRIBUCIÓN DE CLASES ANTES Y DESPUÉS DEL BALANCEO MEDIANTE UNDERSAMPLING.

El conjunto estaba **desbalanceado** (predominaba "fake"), por lo que se aplicó **undersampling** para equilibrarlo y reducir el sesgo del modelo.

COMPARACIÓN DE MODELOS

Modelo	Precision	Recall	AUC
Regresión Logística	0.956	0.838	0.924
Random Forest	0.955	0.830	0.919
GBT	0.957	0.963	0.904

Cuadro II
COMPARACIÓN DEL DESEMPEÑO DE LOS MODELOS EVALUADOS.

Todos los modelos tienen alta precisión; el **GBT destaca por su mayor recall** (menos falsos negativos), mientras que la **Regresión Logística logra el mejor AUC** (mejor discriminación global).

RESULTADOS

MATRIZ DE CONFUSIÓN - LOGISTIC REGRESSION

Muestra buen desempeño general, pero presenta **varios falsos negativos**, lo que reduce su capacidad para detectar audios falsos.

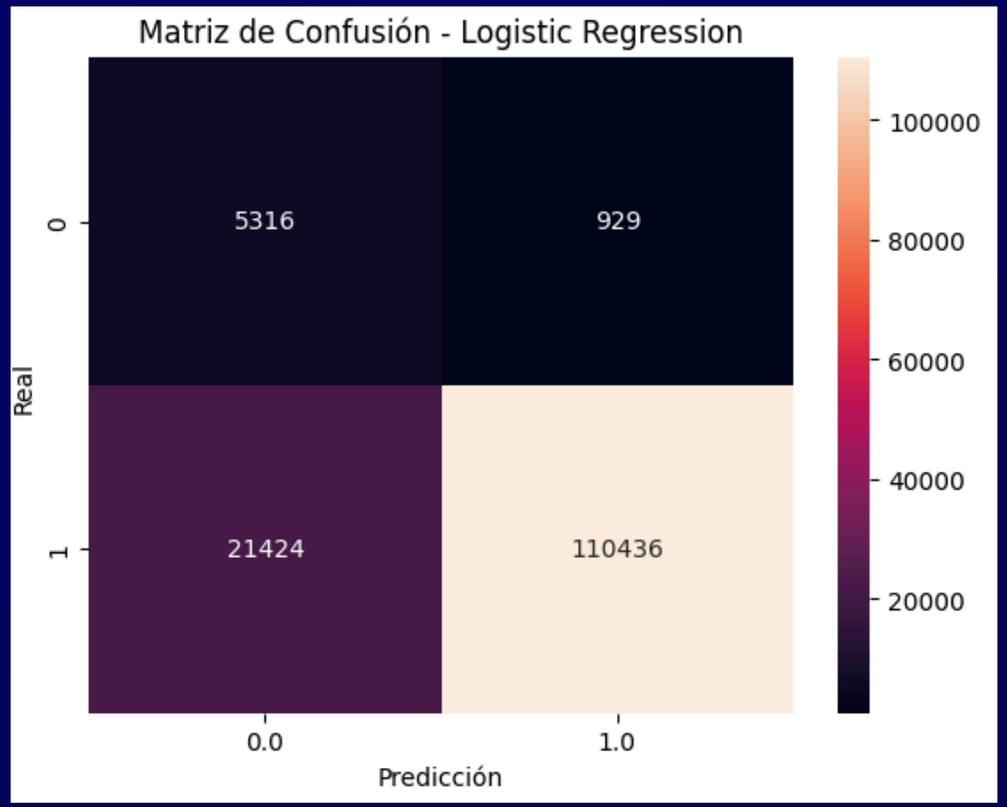

MATRIZ DE CONFUSIÓN - RANDOM FOREST

Presenta un comportamiento similar al anterior, con leves variaciones en las predicciones, pero aún con **limitaciones para detectar completamente la clase positiva**.

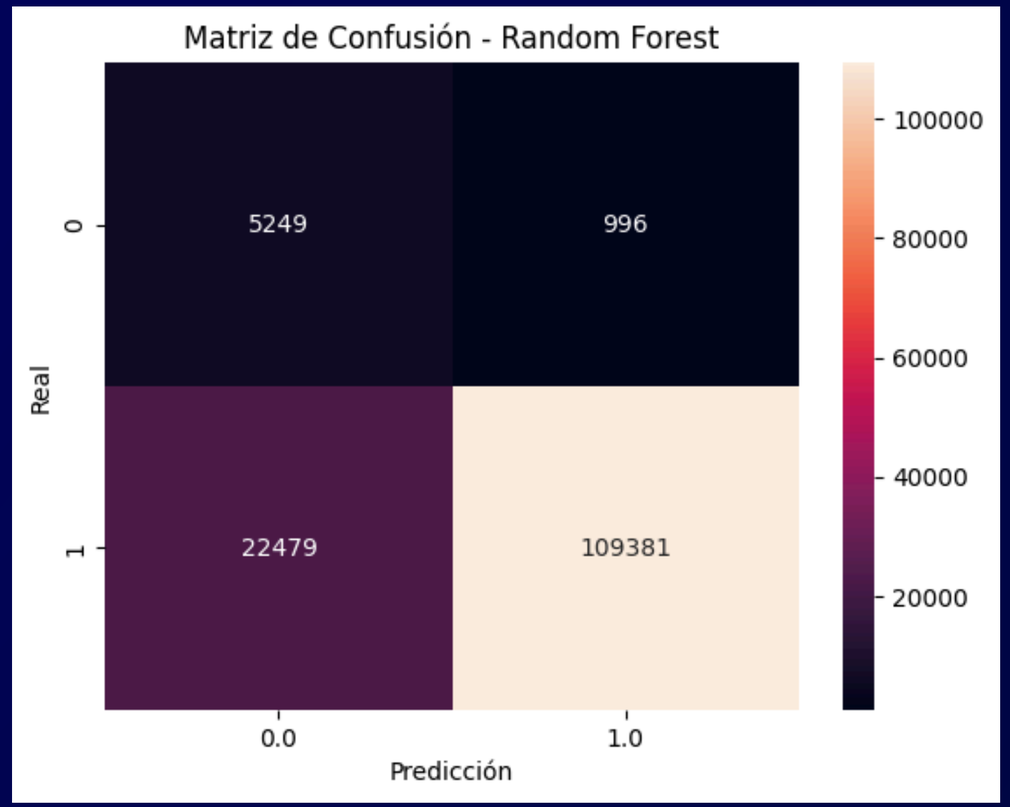

RESULTADOS

MATRIZ DE CONFUSIÓN – GRADIENT BOOSTED TREEST

Presenta una notable **reducción de falsos negativos**, lo que se refleja en un mayor recall y mejor detección de audios falsos.

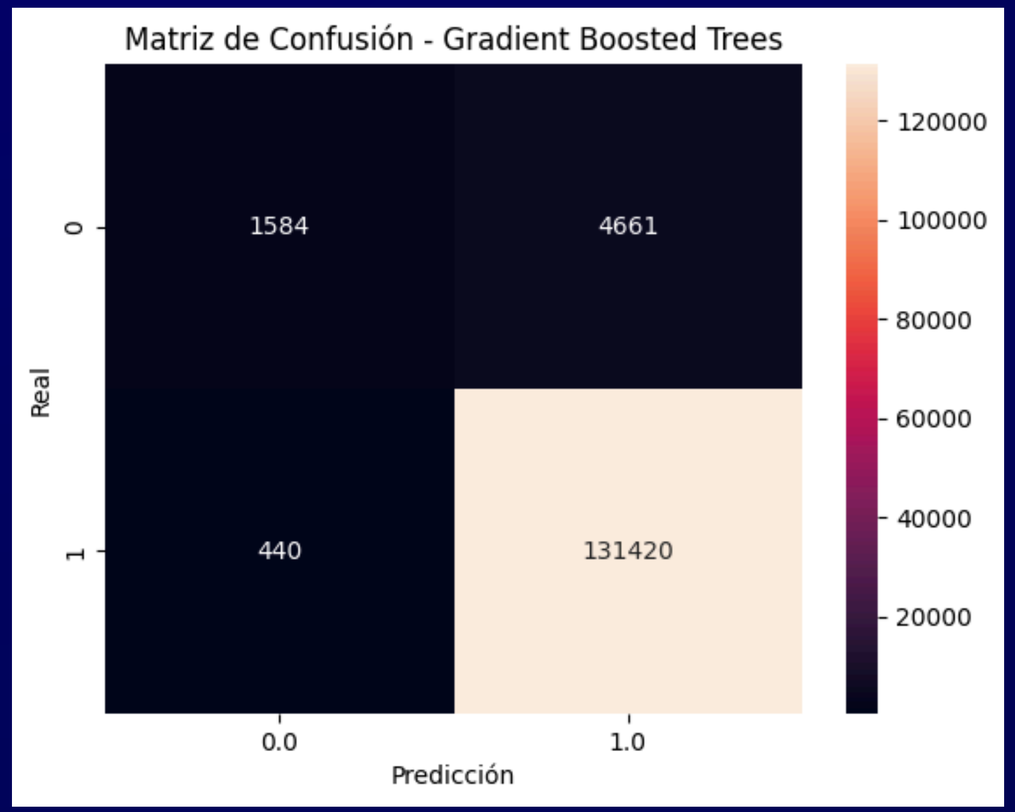

CURVA ROC – COMPARACIÓN DE MODELOS

Todos los modelos muestran buen desempeño (AUC > 0.90); la **Regresión Logística** tiene el **mejor AUC**, el **GBT** es **más adecuado para fraude** porque detecta más audios falsos (mayor recall).

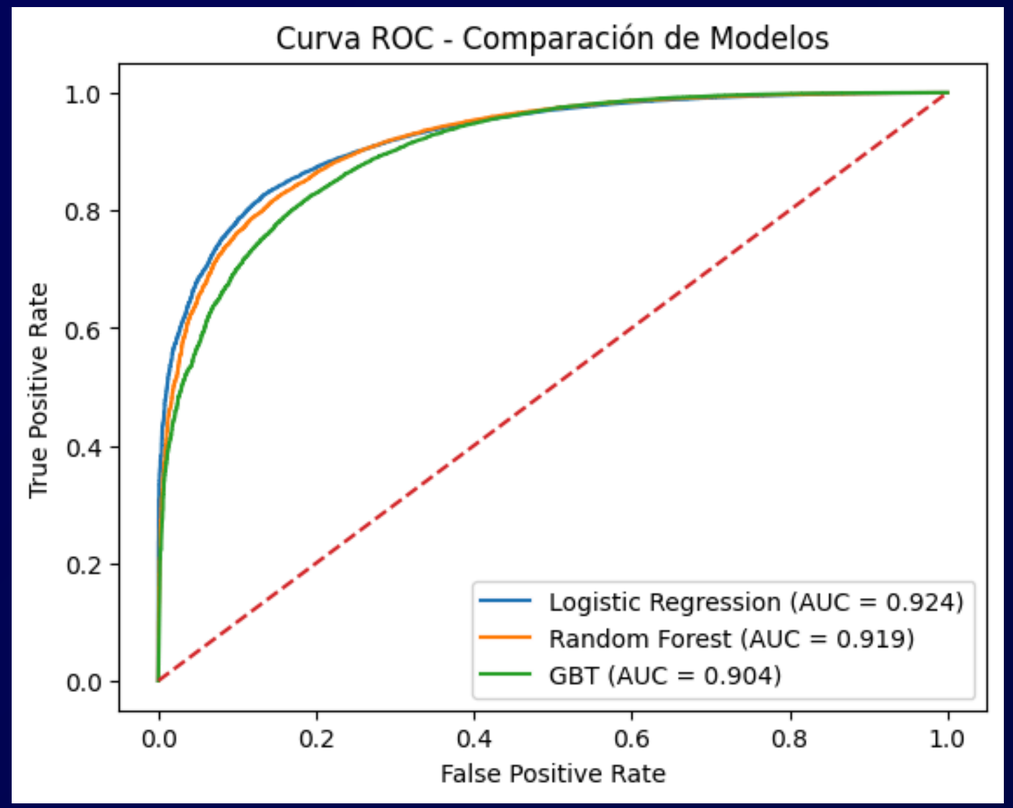

EXTENSIÓN DEL TRABAJO (SEGUNDA PARTE)

SEGUNDA ETAPA DEL PROYECTO

- Procesamiento de audio crudo (no embeddings precomputados)
- Aplicación de técnicas de vectorización (wav2vec)

APLICACIÓN EN ESCENARIOS REALES

- Simulación de detección en tiempo real
- Enfoque tipo sistema: entrada de audio → detección automática

OBJETIVO DE EXTENSIÓN

- Evaluar generalización en datos reales
- Acercar el modelo a una aplicación práctica

CONCLUSIONES

- Se abordó la detección de **audios deepfake** usando embeddings (**wav2vec**).
- Todos los modelos (Regresión Logística, Random Forest y GBT) lograron **alto desempeño** (precisión y AUC).
- **GBT** destaca por su **mayor recall**, siendo mejor para reducir falsos negativos.
- La **Regresión Logística** presenta el **mejor AUC** (mejor discriminación global).
- El balanceo de clases fue clave para mejorar la detección de la clase minoritaria.
- Es posible **diferenciar eficazmente audios reales y sintéticos**, aunque falta evaluar la generalización.

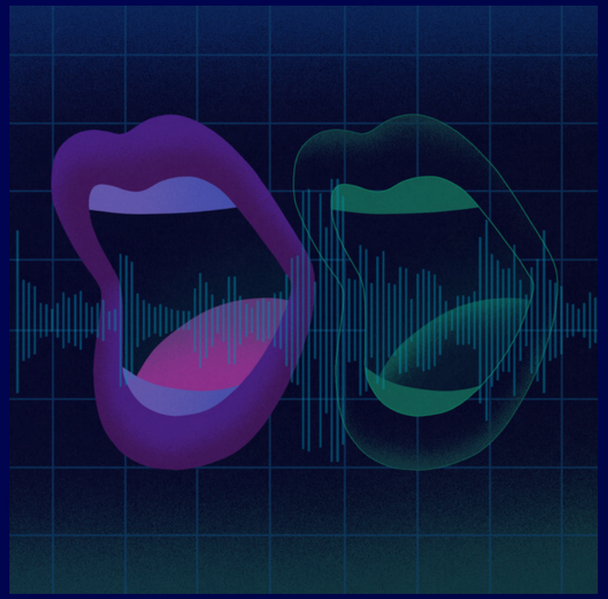

BIBLIOGRAFÍA

- Stupp, C. (2019). Fraudsters used AI to mimic CEO's voice in unusual cybercrime case. The Wall Street Journal. https://www.wsj.com/articles/fraudsters-use-ai-to-mimic-ceos-voice-in-unusual-cybercrime-case-11567157402
- Europol. (2022). Facing reality? Law enforcement and the challenge of deepfakes. https://www.europol.europa.eu/publications-events/publications/facing-reality-law-enforcement-and-challenge-of-deepfakes
- Centro Nacional de Planeamiento Estratégico (CEPLAN). (2025). Deepfakes y riesgos en la transformación digital. https://observatorio.ceplan.gob.pe/ficha/r38_2025
- Kang, J., et al. (2024). Enhancing voice spoofing detection models with wav2vec 2.0 and layer selection strategy. arXiv. https://arxiv.org/abs/2402.17127
- Li, X., et al. (2024). Cross-domain audio deepfake detection: Dataset and analysis. In Proceedings of EMNLP.
- Chetia Phukan, P., et al. (2024). Heterogeneity over homogeneity: Investigating multilingual speech pre-trained models for detecting audio deepfake. In Findings of NAACL.
- Westerlund, M. (2019). The emergence of deepfake technology: A review. Technology Innovation Management Review, 9(11), 40–53.

THANK YOU