Detección de Fraude por Voz mediante Deepfakes: Análisis de Representaciones de Audio y Modelos de Clasificación en Escenarios Reales

Milagros Valverde Avila
Universidad del Pacífico
Lima, Perú
mm.valverdea@alum.up.edu.pe

Sebastian Minchola Robles
Universidad del Pacífico
Lima, Perú
ws.mincholar@alum.up.edu.pe

Sebastian Guevara Peralta
Universidad del Pacífico
Lima, Perú
sa.guevarap@alum.up.edu.pe

Fiorella Tamariz Pantoja
Universidad del Pacífico
Lima, Perú
fa.tamarizp@alum.up.edu.pe

Margot Torre Solis
Universidad del Pacífico
Lima, Perú
sm.torres@alum.up.edu.pe

***Resumen*—Este proyecto aborda la detección de audios generados mediante técnicas de deepfake con el objetivo de prevenir fraudes por suplantación de voz. Se propone un enfoque basado en el uso de representaciones de audio y modelos de clasificación, evaluando el impacto de distintas estrategias de vectorización en la tarea de distinguir entre audios reales y sintéticos.**

En una primera etapa, se emplean embeddings precomputados basados en modelos de aprendizaje profundo, sobre los cuales se entrenan distintos modelos de clasificación en un entorno de procesamiento distribuido. Posteriormente, se plantea como extensión la evaluación de representaciones generadas a partir de audio crudo, con el fin de analizar su influencia en el desempeño del sistema.

Los resultados obtenidos evidencian un alto desempeño en métricas de clasificación, destacando la importancia del recall en escenarios de detección de fraude. Asimismo, se busca evaluar la capacidad de generalización del modelo mediante pruebas en datos externos, contribuyendo al desarrollo de soluciones más robustas para la seguridad digital en contextos reales.

***Index Terms*—deepfake, audio, representaciones de audio, machine learning, fraude, Big Data, clasificación**

I. Introducción

El avance reciente en técnicas de inteligencia artificial ha permitido el desarrollo de sistemas capaces de generar contenido sintético altamente realista, incluyendo voz humana. En particular, los modelos de clonación de voz y síntesis de audio, basados en arquitecturas de aprendizaje profundo, han dado lugar a los denominados *deepfakes de audio*, los cuales pueden imitar con gran precisión la voz de una persona real [1]. Estas tecnologías, si bien tienen aplicaciones legítimas en áreas como asistentes virtuales o accesibilidad, también han abierto la puerta a nuevos tipos de fraude y ataques de ingeniería social.

Uno de los usos más preocupantes de estas tecnologías es la realización de llamadas falsas con voces sintéticas que suplantan la identidad de individuos reales. Este tipo de fraude ha sido reportado en múltiples casos recientes. Por ejemplo, en 2019, una empresa en el Reino Unido fue víctima de una estafa donde los atacantes utilizaron inteligencia artificial para imitar la voz del CEO y solicitar una transferencia bancaria fraudulenta [2]. De manera similar, en años recientes se han documentado casos donde delincuentes han utilizado voces generadas por IA para engañar a familiares y solicitar dinero urgente, simulando situaciones de emergencia [3]. Estos incidentes evidencian el creciente riesgo que representan las tecnologías de síntesis de voz en contextos reales.

En el contexto peruano, el avance de la transformación digital ha incrementado la exposición a riesgos asociados a nuevas tecnologías. Según el Centro Nacional de Planeamiento Estratégico (CEPLAN), el uso de deepfakes en fraudes de identidad ha experimentado un crecimiento significativo a nivel global. Entre 2022 y 2023, se identificó un incremento de hasta diez veces en el número de casos, destacando aumentos del 1740 % en América del Norte, 1530 % en Asia Pacífico y 410 % en América Latina [4]. Este crecimiento evidencia la rápida expansión de estas tecnologías y su potencial uso en actividades fraudulentas, incluyendo la suplantación de identidad mediante voz en entornos digitales y financieros.

En este contexto, surge la necesidad de desarrollar métodos automáticos capaces de detectar si un audio ha sido generado artificialmente o corresponde a una voz humana real. Sin embargo, este problema presenta múltiples desafíos, ya que los modelos generativos continúan evolucionando rápidamente, reduciendo las diferencias perceptibles entre audio real y sintético. Además, los métodos tradicionales de análisis de audio, basados en características manuales como MFCC, pueden resultar insuficientes para capturar patrones complejos presentes en deepfakes modernos.

Diversos estudios recientes han demostrado que el uso de representaciones aprendidas mediante modelos de aprendizaje profundo auto-supervisado, como *wav2vec*, permite capturar características acústicas y semánticas de alto nivel, mejorando el desempeño en tareas de detección de audio sintético [5]–[7]. No obstante, la elección de la representación de audio

adecuada continúa siendo un aspecto crítico, especialmente en términos de generalización frente a datos no vistos.

En este contexto, el problema específico que se aborda en el presente trabajo es la detección automática de audios generados mediante técnicas de *deepfake* en escenarios de fraude por suplantación de voz, formulado como una tarea de clasificación binaria.

Para ello, se propone un enfoque basado en el uso de embeddings de audio precomputados y modelos de clasificación aplicados en un entorno de procesamiento distribuido. Asimismo, se plantea como extensión la evaluación de distintas estrategias de vectorización a partir de audio crudo, con el objetivo de analizar el impacto de la representación en el desempeño del sistema.

La relevancia de este problema radica no solo en sus implicancias en la seguridad digital y la confianza en sistemas de comunicación, sino también en su impacto económico. En particular, se busca evaluar no solo el desempeño de los modelos en escenarios controlados, sino también su capacidad de generalización frente a datos externos, acercándose a condiciones reales de uso.

I-A. Preguntas de investigación

El presente trabajo busca responder las siguientes preguntas:

- ¿Es posible diferenciar de manera efectiva entre audios reales y audios generados mediante técnicas de *deepfake* utilizando representaciones de audio basadas en modelos de aprendizaje profundo?
- ¿Qué impacto tiene la elección de la representación de audio en el desempeño de los modelos de clasificación en la tarea de detección de voces falsas?
- ¿Qué limitaciones presenta este tipo de enfoque en términos de generalización frente a datos no vistos o provenientes de contextos reales?

I-B. Objetivo general

Desarrollar y evaluar un modelo de clasificación capaz de detectar audios generados mediante técnicas de *deepfake*, analizando el impacto de distintas representaciones de audio en su desempeño y capacidad de generalización.

I-C. Objetivos específicos

- Implementar un pipeline de procesamiento de datos basado en representaciones precomputadas del dataset seleccionado, utilizando herramientas de procesamiento distribuido.
- Entrenar modelos de clasificación binaria para diferenciar entre audios reales y falsos.
- Evaluar el desempeño de los modelos utilizando métricas como *precision*, *recall* y AUC.
- Analizar el impacto de diferentes estrategias de representación de audio en el desempeño del modelo.
- Evaluar la capacidad de generalización del modelo frente a datos no utilizados durante el entrenamiento.

I-D. Hipótesis

Se plantea que el uso de representaciones de audio basadas en modelos de aprendizaje profundo permite capturar patrones complejos presentes en audios sintéticos, logrando un mejor desempeño en métricas de clasificación en comparación con métodos tradicionales basados en características manuales. Asimismo, se espera que la elección de la representación de audio tenga un impacto significativo en el desempeño y capacidad de generalización del modelo.

II. Estado del Arte

En los últimos años, la detección de audio deepfake ha sido ampliamente estudiada debido al rápido avance de los modelos generativos de voz, los cuales han incrementado significativamente el realismo de los audios sintéticos. En este contexto, diversos enfoques han sido propuestos, destacando especialmente aquellos basados en representaciones aprendidas mediante modelos de aprendizaje profundo autosupervisado.

En primer lugar, Kang et al. [5] abordan el problema de la detección de ataques de suplantación de voz (*voice spoofing*) mediante el uso de representaciones profundas de audio. Para ello, utilizan el dataset ASVspoof 2019, ampliamente empleado en la evaluación de sistemas de detección de audio falso. Su enfoque se basa en el uso de *wav2vec 2.0* como modelo de extracción de características, junto con estrategias de selección de capas y modelos de clasificación como RawNet2 y AASIST. Los resultados obtenidos muestran una mejora significativa frente a métodos tradicionales, evidenciando la capacidad de las representaciones profundas para capturar patrones complejos en señales de audio.

Por otro lado, Li et al. [6] estudian la detección de audio deepfake en escenarios de generalización entre dominios, donde los modelos deben enfrentarse a datos provenientes de distintas distribuciones. Para ello, construyen un dataset de gran escala que incluye más de 300 horas de audio generado por múltiples sistemas de síntesis de voz. Su metodología emplea modelos preentrenados, incluyendo variantes de *wav2vec*, evaluando su desempeño bajo diferentes condiciones. Los resultados evidencian que, si bien estos modelos alcanzan un buen rendimiento en entornos controlados, la generalización sigue siendo un desafío importante cuando se aplican a datos no vistos.

Finalmente, Chetia Phukan et al. [7] investigan el uso de modelos de representación de voz preentrenados en diferentes idiomas para la detección de audio deepfake. Utilizan diversos datasets de referencia, incluyendo ASVspoof 2019 e In-the-Wild, con el objetivo de comparar el desempeño de modelos monolingües y multilingües. Los resultados muestran que los modelos multilingües pueden ofrecer un mejor desempeño en escenarios diversos, lo que sugiere una mayor capacidad de generalización en comparación con enfoques más especializados.

En conjunto, estos trabajos evidencian una tendencia clara hacia el uso de representaciones profundas de audio como base para la detección de deepfakes, debido a su capacidad

para capturar información acústica y semántica de alto nivel. Sin embargo, también coinciden en que la elección de la representación de audio y la capacidad de generalización de los modelos continúan siendo desafíos abiertos, especialmente cuando se enfrentan a datos provenientes de diferentes contextos.

En este marco, el presente trabajo se alinea con esta línea de investigación al utilizar representaciones basadas en *wav2vec* en una primera etapa. No obstante, a diferencia de enfoques previos, se propone analizar el impacto de distintas estrategias de representación de audio en el desempeño de modelos de clasificación, manteniendo constante el modelo y variando únicamente la vectorización. Asimismo, se plantea evaluar la capacidad de generalización del sistema en datos externos, contribuyendo así a una mejor comprensión de su aplicabilidad en escenarios reales.

Estos trabajos fundamentan el uso de representaciones basadas en wav2vec en nuestro enfoque, así como la necesidad de evaluar la capacidad de generalización del modelo frente a datos no vistos. En particular, se toma como base el uso de embeddings precomputados, mientras que se propone como aporte el análisis del impacto de distintas estrategias de representación manteniendo constante el modelo de clasificación.

III. Metodología

En esta sección se describe la metodología empleada para la detección de audios generados mediante técnicas de *deepfake*, utilizando representaciones de audio basadas en modelos de aprendizaje auto-supervisado. El enfoque se centra en el uso de embeddings precomputados obtenidos mediante *wav2vec*, sobre los cuales se aplican distintos modelos de clasificación en un entorno de procesamiento distribuido.

III-A. Formulación del problema

El problema abordado corresponde a una tarea de clasificación binaria. Sea un conjunto de muestras $X = \{x_1, x_2, ..., x_n\}$, donde cada instancia $x_i \in \mathbb{R}^{768}$ representa un vector de características obtenido a partir de un segmento de audio mediante el modelo *wav2vec*. Cada muestra está asociada a una etiqueta $y_i \in \{0, 1\}$, donde 0 indica audio real y 1 indica audio generado artificialmente.

El objetivo es aprender una función de clasificación $f : \mathbb{R}^{768} \to \{0, 1\}$ que permita predecir correctamente la etiqueta de cada muestra, maximizando su capacidad de generalización frente a datos no vistos y potencialmente provenientes de contextos reales.

III-B. Descripción del dataset

Para el desarrollo de este estudio se utiliza un subconjunto del dataset *DeepFakeVoice-Wav2Vec-4Datasets*, específicamente las particiones de entrenamiento y prueba derivadas de ASVspoof 2021. Este conjunto de datos contiene representaciones de audio precomputadas en formato *parquet*, donde cada muestra corresponde a un embedding de 768 dimensiones generado mediante el modelo *wav2vec*, junto con una etiqueta binaria que indica si el audio es real o sintético.

El conjunto de entrenamiento tiene un tamaño aproximado de 1.7 GB, mientras que el conjunto de prueba alcanza aproximadamente 426 MB, lo que justifica el uso de herramientas de procesamiento distribuido.

Cada muestra del dataset está compuesta por:

- Un conjunto de variables numéricas correspondientes a los embeddings (`emb_*`)
- Una etiqueta categórica que indica si el audio es real o falso

Estas representaciones permiten capturar características acústicas complejas sin necesidad de procesar directamente el audio crudo, reduciendo la complejidad computacional del problema.

III-C. Pipeline de procesamiento

El procesamiento de los datos se realiza utilizando Apache Spark en el entorno Databricks, lo cual permite manejar eficientemente grandes volúmenes de información bajo un enfoque de Big Data.

El flujo de trabajo consta de las siguientes etapas:

- **Carga de datos**: los archivos en formato *Parquet* son cargados desde almacenamiento distribuido (volúmenes).
- **Construcción de variables**: las columnas correspondientes a los embeddings (`emb_*`) son combinadas en un único vector de características mediante la herramienta *VectorAssembler*, generando la variable `features`.
- **Transformación de etiquetas**: la variable categórica es convertida a formato binario, donde la clase `fake` se asigna a 1 y la clase real a 0.
- **Balanceo de datos**: debido al desbalance en las clases, se aplica una estrategia de submuestreo (*undersampling*) sobre la clase mayoritaria, con el objetivo de obtener un conjunto de entrenamiento balanceado y mejorar la capacidad de aprendizaje de los modelos.

Este pipeline permite estructurar el flujo de datos de manera eficiente, escalable y reproducible dentro del entorno distribuido.

III-D. Modelos de clasificación

Se emplean tres modelos de clasificación con diferentes niveles de complejidad:

- **Regresión Logística**: modelo lineal utilizado como línea base, adecuado cuando las clases son separables en el espacio de características.
- **Random Forest**: modelo de ensamble basado en múltiples árboles de decisión, capaz de capturar relaciones no lineales y reducir la varianza.
- **Gradient Boosted Trees (GBT)**: modelo basado en boosting que construye árboles de forma secuencial, optimizando los errores del modelo previo y capturando patrones más complejos.

La inclusión de modelos con distintas capacidades permite analizar el impacto de la complejidad del modelo en el desempeño de la tarea.

III-E. *Configuración experimental*

Para la evaluación de los modelos se utiliza la partición entrenamiento/prueba proporcionada por el dataset. El entrenamiento se realiza sobre el conjunto balanceado, mientras que la evaluación se lleva a cabo sobre el conjunto de prueba original, con el fin de simular un escenario real.

Se emplean las siguientes métricas de evaluación:

- **Precisión (Precision)**: proporción de predicciones positivas correctas.
- **Recall**: proporción de verdaderos positivos detectados, especialmente relevante en problemas de fraude y detección de deepfakes.
- **AUC (Área bajo la curva ROC)**: mide la capacidad del modelo para distinguir entre clases a distintos umbrales de decisión, siendo especialmente útil en contextos con desbalance de clases.

Adicionalmente, se construyen matrices de confusión para analizar el desempeño en términos de falsos positivos y falsos negativos, así como curvas ROC para comparar visualmente la capacidad discriminativa de los modelos.

Finalmente, como extensión del trabajo, se plantea evaluar en etapas posteriores la capacidad de generalización del modelo en datos externos no utilizados durante el entrenamiento.

IV. Resultados

Se evaluaron tres modelos de clasificación: Regresión Logística, Random Forest y Gradient Boosted Trees (GBT), utilizando métricas de precisión, recall y AUC, con el objetivo de medir su capacidad para detectar audios generados mediante técnicas de *deepfake*.

IV-A. *Distribución de clases*

Antes del proceso de balanceo, el conjunto de entrenamiento presentaba un desbalance significativo entre clases, como se muestra en la Tabla I.

Conjunto	Clase	Cantidad
Entrenamiento (original)	Fake (1)	525,677
	Real (0)	24,508
Entrenamiento (balanceado)	Fake (1)	24,479
	Real (0)	24,508

Cuadro I
DISTRIBUCIÓN DE CLASES ANTES Y DESPUÉS DEL BALANCEO MEDIANTE UNDERSAMPLING.

Se observa un fuerte desbalance en el conjunto de entrenamiento original, donde la clase ”fake”supera ampliamente a la clase real”. Para mitigar este problema, se aplicó una técnica de *undersampling*, reduciendo la cantidad de muestras de la clase mayoritaria hasta lograr una distribución balanceada.

Este proceso permite mejorar la capacidad de los modelos para aprender patrones de ambas clases y evitar sesgos hacia la clase predominante.

Modelo	Precision	Recall	AUC
Regresión Logística	0.956	0.838	0.924
Random Forest	0.955	0.830	0.919
GBT	0.957	0.963	0.904

Cuadro II
COMPARACIÓN DEL DESEMPEÑO DE LOS MODELOS EVALUADOS.

IV-B. *Comparación de modelos*

Los resultados obtenidos en el conjunto de prueba se resumen en la Tabla II.

Como se observa en la Tabla II, todos los modelos presentan un alto desempeño en términos de precisión, lo que indica una adecuada capacidad para clasificar correctamente los audios.

Sin embargo, el modelo GBT destaca por alcanzar el mayor valor de *recall* (0.963), lo que implica una menor cantidad de falsos negativos. Este aspecto resulta especialmente relevante en el contexto de detección de deepfakes, donde es crítico minimizar los casos de audios falsos que no son detectados.

Por otro lado, la Regresión Logística presenta el mayor valor de AUC (0.924), lo que indica una mejor capacidad global de discriminación entre clases.

IV-C. *Matrices de confusión*

Las Figuras 1, 2 y 3 muestran las matrices de confusión para cada uno de los modelos evaluados.

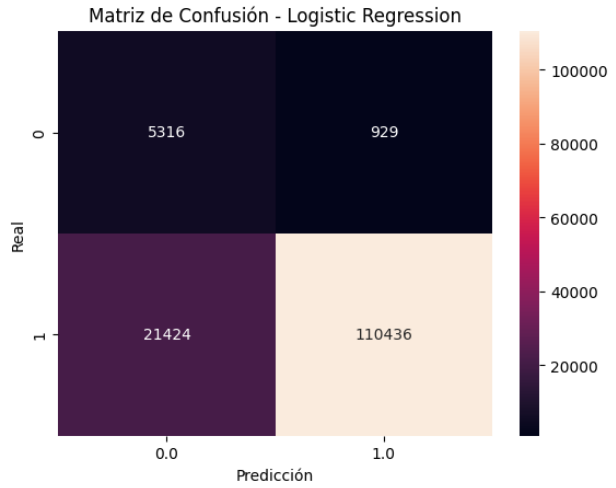

Figura 1. Matriz de confusión para el modelo de Regresión Logística.

En la Figura 1, correspondiente a la regresión logística, se observa un buen desempeño general; sin embargo, el modelo presenta una cantidad relevante de falsos negativos, lo que limita su capacidad para detectar todos los casos de audio falso.

El modelo Random Forest (Figura 2) presenta un comportamiento similar al de la regresión logística, con ligeras variaciones en la distribución de predicciones, pero manteniendo limitaciones en la detección completa de la clase positiva.

En contraste, el modelo GBT muestra una reducción significativa en los falsos negativos, lo cual explica su mayor valor

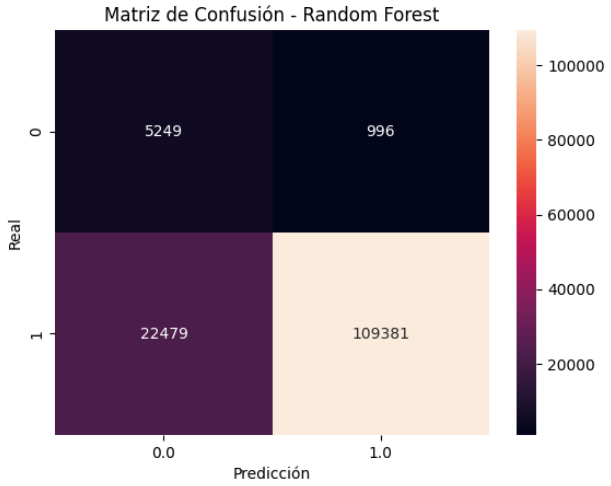

Figura 2. Matriz de confusión para el modelo Random Forest.

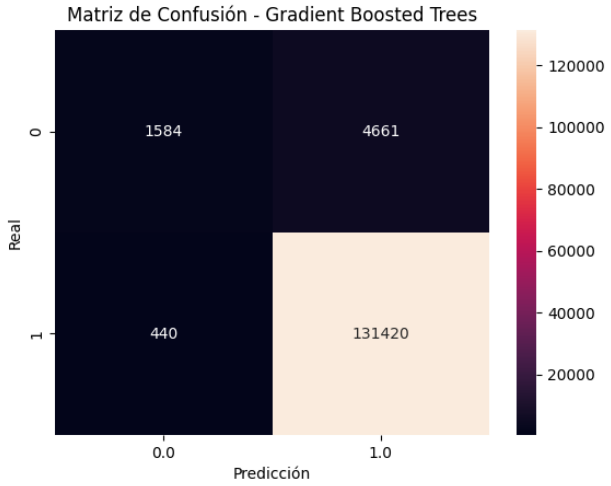

Figura 3. Matriz de confusión para el modelo Gradient Boosted Trees.

de *recall* y evidencia una mayor sensibilidad hacia la detección de audios falsos.

IV-D. *Curva ROC*

La Figura 4 presenta la curva ROC para los tres modelos evaluados.

Se observa que todos los modelos presentan un buen desempeño en términos de discriminación entre clases, con valores de AUC superiores a 0.90. La Regresión Logística alcanza el mayor valor de AUC, seguida de Random Forest y GBT.

No obstante, aunque la Regresión Logística presenta un mejor AUC, este resultado refleja el desempeño global del modelo. En escenarios donde la prioridad es minimizar falsos negativos, como en la detección de deepfakes, el modelo GBT resulta más adecuado debido a su mayor capacidad de detección de la clase positiva.

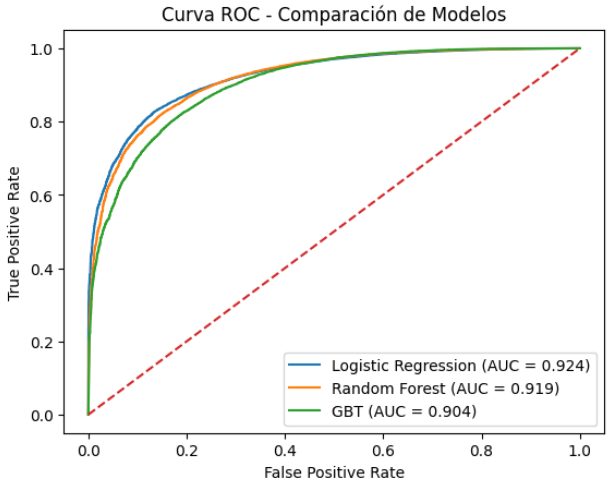

Figura 4. Curva ROC comparativa entre los modelos evaluados.

IV-E. *Análisis general*

Los resultados evidencian que el uso de embeddings generados mediante *wav2vec* permite alcanzar un alto desempeño en la detección de audios deepfake, incluso utilizando modelos tradicionales de aprendizaje automático.

Asimismo, se observa que, dado que los embeddings capturan información acústica y semántica relevante, modelos más simples como la Regresión Logística pueden lograr un desempeño competitivo. Sin embargo, modelos más complejos como GBT muestran ventajas en términos de sensibilidad, al mejorar la detección de la clase minoritaria.

En conjunto, estos resultados sugieren que la elección del modelo debe considerar no solo métricas globales como AUC, sino también métricas específicas como el *recall*, dependiendo del contexto de aplicación.

IV-F. *Extensión del proyecto: selección de modelo y procesamiento de audio crudo*

A partir de los resultados obtenidos en esta primera etapa, se identifica que el modelo Gradient Boosted Trees (GBT) presenta el mejor desempeño en términos de *recall*, lo cual resulta especialmente relevante en el contexto de detección de deepfakes, donde es crítico minimizar los falsos negativos.

En base a este criterio, el modelo GBT será utilizado como base para el desarrollo de la siguiente etapa del proyecto.

Adicionalmente, se plantea extender el enfoque actual hacia el procesamiento de audio crudo, explorando distintas estrategias de vectorización mediante modelos de aprendizaje profundo como *wav2vec*. En particular, se evaluarán diferentes configuraciones para la generación de embeddings directamente a partir de señales de audio, con el objetivo de analizar su impacto en el desempeño del modelo de clasificación.

De esta manera, se buscará identificar la combinación más adecuada entre el modelo de clasificación y el método de representación de audio, considerando métricas como *recall*, *precision* y AUC.

Finalmente, como validación adicional, se propone realizar pruebas con audios externos no utilizados durante el entrenamiento, incluyendo tanto audios reales como sintéticos, con el fin de evaluar la capacidad de generalización del sistema en escenarios más cercanos a condiciones reales.

V. Conclusiones

En el presente trabajo se abordó el problema de la detección de audios generados mediante técnicas de *deepfake*, utilizando representaciones de audio basadas en embeddings obtenidos a partir de modelos de aprendizaje profundo como *wav2vec*.

Los resultados obtenidos evidencian que este tipo de representaciones permite alcanzar un alto desempeño en tareas de clasificación, incluso mediante el uso de modelos tradicionales de aprendizaje automático. En particular, todos los modelos evaluados lograron valores elevados de precisión y AUC, lo que confirma la capacidad de los embeddings para capturar características relevantes de las señales de audio.

Asimismo, se identificó que el modelo Gradient Boosted Trees (GBT) presenta una ventaja significativa en términos de *recall*, lo que lo convierte en la alternativa más adecuada en contextos donde es prioritario minimizar la cantidad de falsos negativos, como en la detección de fraude o suplantación de identidad.

Por otro lado, se evidenció la importancia del balanceo de clases en el proceso de entrenamiento, ya que permitió mejorar la capacidad de los modelos para detectar correctamente la clase minoritaria y evitar sesgos hacia la clase predominante.

En relación con las preguntas de investigación planteadas, se concluye que es posible diferenciar de manera efectiva entre audios reales y audios sintéticos mediante el uso de representaciones basadas en *wav2vec*, alcanzando un alto nivel de desempeño. No obstante, también se reconoce que la capacidad de generalización del modelo frente a datos no vistos constituye un aspecto clave que debe ser evaluado en mayor profundidad.

Como trabajo futuro, se propone extender el enfoque hacia el procesamiento de audio crudo y la evaluación del modelo en datos externos, con el fin de analizar su desempeño en escenarios más cercanos a condiciones reales y fortalecer su aplicabilidad práctica.

Referencias

[1] M. Westerlund, "The emergence of deepfake technology: A review," *Technology Innovation Management Review*, vol. 9, no. 11, pp. 40–53, 2019.

[2] C. Stupp, "Fraudsters used ai to mimic ceo's voice in unusual cybercrime case," *The Wall Street Journal*, 2019.

[3] Europol, "Facing reality? law enforcement and the challenge of deepfakes," 2022.

[4] Centro Nacional de Planeamiento Estratégico, "Deepfakes y riesgos en la transformación digital," 2025. [Online]. Available: https://observatorio.ceplan.gob.pe/ficha/r38_2025

[5] J. Kang *et al.*, "Enhancing voice spoofing detection models with wav2vec 2.0 and layer selection strategy," *arXiv preprint arXiv:2402.17127*, 2024.

[6] X. Li *et al.*, "Cross-domain audio deepfake detection: Dataset and analysis," in *Proceedings of EMNLP*, 2024.

[7] P. Chetia Phukan *et al.*, "Heterogeneity over homogeneity: Investigating multilingual speech pre-trained models for detecting audio deepfake," in *Findings of NAACL*, 2024.